

# Encoder-Decoder LSTM 기반 바나나 신선도 변화 예측 및 XAI 기법 적용 연구

박우현<sup>01</sup>, 나강민<sup>2</sup>, 김규민<sup>3</sup>

<sup>1</sup>충북과학고등학교, <sup>2</sup>충북과학고등학교, <sup>3</sup>충북과학고등학교

[parkwoohyun10@gmail.com](mailto:parkwoohyun10@gmail.com), [kangmin3374@gmail.com](mailto:kangmin3374@gmail.com), [kbabee0712@gmail.com](mailto:kbabee0712@gmail.com)

## Prediction of Banana Freshness Using an Encoder-Decoder LSTM Model with Explainable AI (XAI)

Woohyun Park<sup>01</sup>, Kangmin Ra<sup>2</sup>, Gyumin Kim<sup>3</sup>,

<sup>1</sup>Chungbuk Science High School, <sup>2</sup>Chungbuk Science High School, <sup>3</sup>Chungbuk Science High School

[parkwoohyun10@gmail.com](mailto:parkwoohyun10@gmail.com), [kangmin3374@gmail.com](mailto:kangmin3374@gmail.com), [kbabee0712@gmail.com](mailto:kbabee0712@gmail.com)

### 요약

바나나의 신선도 예측은 과일 산업에서 품질 보존 측면에서 매우 중요시 여겨지고 있다. 본 연구는 다양한 환경에서 1시간 간격으로 촬영된 바나나 시계열 이미지를 이용해 새로운 환경에서 초기 일부 구간(10%-30%)만 관측하더라도 남은 저장 기간 전체의 연속 신선도 곡선을 예측할 수 있는 가변 길이 Encoder-Decoder LSTM 모델을 제안한다. 모델은 입력 길이에 따라 복제 횟수를 자동 조정하는 Repeat Vector Dynamic(RVD) Layer와 Additive Attention을 결합해 가변 시퀀스 학습을 지원한다. 동일 입력 조건에서 전통 시계열(ARIMA)과 딥러닝 기반 베이스라인(GRU)을 비교한 결과, 제안 모델은 입력 시퀀스 비율 25%에서 MAE 0.0434를 기록해 GRU 대비 MAE를 최대 69% 낮추었다. 입력 비율이 10%일 때는 오차가 증가하지만 25% 이상에서는 성능이 수렴하였다. 어텐션 히트맵 분석 결과, 후반부 입력 프레임일수록 높은 가중치를 부여받아 시간 경과에 따른 숙성 정보가 예측에 결정적임을 확인하였다.

### 1. 서론 및 이론적 배경

#### 1.1 연구 동기 및 목적

바나나는 전세계적으로 가장 많이 소비되는 과일 중 하나이며 전세계 과일량의 약 16% 이상을 차지한다. 연간 약 2000만t 이상이 거래되며 저장과정에서 품질 저하로 인한 손실만 평균적으로 7%를 넘는다. 품질 관리 및 소비자 만족을 위해서는 바나나의 신선도를 효과적으로 관리할 필요가 있고, 이를 위해 기존의 저장환경 모니터링 시스템과 차별화된 신선도 변화 예측 모델이 필요하다.

기존에는 온도나 습도를 제어하거나 숙련된 작업자가 일일이 확인하면서 신선도 변화를 분석·예측해왔다. 하지만 이 방법에는 시간과 인력 소모가 크고, 변화의 세밀한 추이를 반영하기 어렵다는 한계가 있다. 이에 따라 최근에는 신선도를 예측하는 모델의 필요성이 부각되고 있다. 지금까지 여러 신선도 예측 모델이 제안되어 왔지만, 대부분의 연구는 기본적으로 특정 시점의 신선도를 판별하거나 단기적인 예측에서 끝나는 경우가 많아 장기적인 변화 추이를 반영하는데에는 한계점이 있었다. 또한 지금까지의 모델들은 특정 환경의 데이터만을 이용하여 학습하였기에 동일한 저장환경의 바나나에 대해서만 신선도 예측을 수행할 수 있었다. [1][2][3]

본 연구에서는 신선도의 특징을 활용하여 본 문제를 해결하고자 하였다. 과일의 신선도는 저장환경에 따라 감소하는 속도에 차이가 있다. 온습도가 높으면 더욱 빨리 신선도가 떨어진다. 또한, 신선도는 시간이 지날수록 급격히 감소하는 경향을 보인다. 그렇기에 바나나의 신선도 추세 자체를 학습하는 모델을 설계하여 다양한 환경의 데이터를 학습시키면 어떠한 환경에 대해서도 앞부분 일부의 신선도 변화 추세만을 이용하여 전체 신선도 변화를 예측해볼 수 있을 것이라고 생각하였다. 본 연구에서는 이를 바탕으로 신선도 변화 예측 모델을 제안·실험하고자 한다.

즉, 어떤 환경인지 알 수 없는 어느 한 바나나의  $n$ 시간 동안 신선도 추세 변화를 입력하면, 그 이후 추세를 예측하는 모델을 제안한다.

사용자가 입력으로 긴 시간동안의 신선도 변화를 입력할수록 정확도가 높아지므로 얼마나 많은 시간에 대한 신선도 변화추세를 입력해야 특정 정확도 이상의 예측결과가 나오는지 알아내는 것 역시 본 연구의 주된 목표로 설정하였다. 더 나아가, XAI를 이용하여 모델이 도출한 미래 신선도 변화에 대한 예측 이유를 설명하도록 Attention Heatmap 기법을 적용하여 모델의 예측결과에 대한 신뢰성을 향상시키고자 한다.

본 연구는 본 모델을 이용해 환경의 제약 없이 바나나의 신선도 변화를 예측하며 모델의 예측 판단 이유를 사용자에게 명확히 설명해내는 것을 목표로 한다.

#### 1.2 이론적 배경

인코더(encoder)는 입력 시퀀스를 하나의 context vector로 요약하여 디코더(decoder)에게 전달한다. 디코더는 이 context vector를 초기 조건으로 하여 출력 시퀀스를 단계적으로 생성한다.

LSTM(Long Short-Term Memory)은 전통적인 RNN의 기울기 소실 문제점을 해결한 모델 구조이다. RNN과 마찬가지로 반복되는 셀로 이루어져 있으며, 인코더 & 디코더 구조에서 LSTM의 hidden state와 cell state를 통해 연속적인 시간에서 각 시점간의 연관성을 유지하는 것이다.

Attention HeatMap은 XAI 기법의 한 종류로, 토큰간의 어텐션과 가중치를 2차원 heatmap으로 나타내 시각화하는 것이다. 쿼리( $Q$ )와 키( $K$ )의 dot product를 통해 각각의 쿼리와 키의 유사도를 구하고 softmax 함수를 적용하여 어텐션 가중치인  $\alpha$ 를 얻을 수 있다.

## 2. 데이터 수집 및 전처리

### 2.1 데이터 수집

본 연구에서는 바나나의 신선도 변화를 예측하기 위해 Kaggle 등 공개된 온라인 데이터셋 저장소에서 수집한 시간별 이미지 데이터를 활용하였다. 사용한 데이터셋은 여러 다양한 환경에서 각각 바나나의 외형 변화를 1시간 간격으로 촬영한 이미지 시퀀스로 구성되어 있으며, 다양한 신선도 변화 양상을 학습할 수 있도록 하였다.

그림 4 는 다양한 환경에서 시간에 따라 신선도가 어떻게 변화하는지 나타낸 그래프를 모두 통합한 것이다.



그림 1 초기익음단계 그림 2 중간익음단계 그림 3 후반익음단계




그림 4 수집한 바나나 데이터셋의 신선도 변화 분포

### 2.2 데이터 전처리

바나나의 데이터가 이미지 형태로 존재하므로, 모델 훈련을 위해서는 바나나의 신선도를 정량적으로 나타내야할 필요가 있다. 따라서 전체 픽셀 대비 노란색 픽셀의 비율을 바나나의 신선도를 수치적으로 표현하기 위한 기준으로 사용하였으며, 0~1의 값으로 정규화하여 각 이미지에 대한 라벨을 부여하였다. 이를 통해 기존 연구[4]에서 사용되었던 Good/Normal/Bad와 같은 범주형 라벨보다 더 세밀한 신선도 변화 또한 반영할 수 있도록 하였다. 또한 사용자가 이미지를 입력하면 이를 신선도 값으로 전처리하여 모델에 입력한다.

시퀀스 형태의 입력을 받고, 시퀀스 형태의 결과를 내는 모델이므로 학습의 일관성을 위해, 모든 시계열 이미지 시퀀스의 길이는 736개(736시간)로 통일하였다. 최종적으로 구성된 40개의 시퀀스를 대상으로 Train, Test, Validation set을 각각 7:1:2의 비율로 분할해 모델 학습 및 검증에 활용하였다.

## 3. 모델 구조 및 학습

### 3.1 아키텍처 개요

사용자가 어떠한 길이의 입력 시퀀스를 입력할지 알 수 없기에, 본 연구의 모델은 기본적으로 가변 길이 입력이 가능한 인코더-디코더 LSTM 구조를 기반으로 한다. [5][6]

인코더는 앞부분  $n$ 시간의 신선도 시계열 데이터를 입력받아 context vector로 압축하고, 이 context vector는 Repeat-Vector-Dynamic Layer를 거쳐 디코더의 각 셀에 입력값으로 들어간다. 디코더는 LSTM셀 2층(각각 128unit)구조로 구성하였다. 하위층이 단기적인 세부 변화를 감지하도록 하였으며 상위층은 하위층의 출력을 다시 처리하여 추상적·장기적인 패턴을 학습할 수 있도록 하였다.

파라미터 수를 늘리지 않고, 두 개의 층으로 분할 하여 과적합이 줄어드는 효과를 기대하였다.




그림 5 Encoder-Decoder LSTM 모델 아키텍처


또한 Attention을 적용함으로써 디코더가 인코더를 잘 반영할 수 있도록 하였다. 어텐션 가중치를 활용하면 XAI 사용 또한 수월해진다. [7][8][9]

### 3.2 가변 길이 입력 처리

사용자가 입력하는 1시간 간격 사진 시퀀스의 길이를 알 수 없기에 가변 길이를 처리할 모델이 필요하다. 기존 Repeat-Vector는 컨텍스트 벡터를 디코더 시간 단계만큼 고정 복제하지만, Repeat-Vector-Dynamic(RVD) 층은 실제 입력 길이  $k$ 에 따라 복제 횟수  $T-k$ 를 자동 조정한다. 이후 0 패딩과 마스킹을 적용해 서로 다른 길이의 시퀀스를 한 배치에서 문제없이 학습·추론할 수 있도록 설계했다.

### 3.3 모델 학습 파이프라인

표 1 모델 학습 파이프라인



본 모델의 학습에 대한 전반적인 파이프라인은 위 표 1과 같다. 이때, batch generator에서는 매 스텝마다 무작위 길이의 배치를 뽑아 슬라이싱 하여 동일한 입출력 차원을 가지는 훈련용 배치를 만들게 된다. 가변적인 사용자의 입력에 효과적으로 대응하기 위해 훈련 또한 여러 입력 시퀀스 길이로 진행한다.

표 2 하이퍼 파라미터

|                  |              |
|------------------|--------------|
| batch_size       | 16           |
| steps_per_epoch  | 60           |
| validation_steps | 10           |
| epochs           | 30           |
| dropout          | Dropout(0.2) |

학습에 적합한 하이퍼 파라미터 값들은 Grid Search를 통해 얻어냈으며 그 결과는 위 표 2와 같다.

### 3.4 XAI 적용

학습된 모델에 사용자의 입력( $n$ 시간)을 주고 나머지 시간의 신선도 값에 대한 예측을 수행하도록 한다. 이때 각각의 디코더 시점마다 어텐션모듈이 계산한 가중치  $\alpha$ 를 추출한다. 어텐션 가중치를 이용한 히트맵을 그려내어 모델이 각 시점에 대해 어떤 입력 시점에 주목하여 예측을 수행하였는지 확인할 수 있다.

## 4. 결과 및 결론

### 4.1. 모델 성능 분석

모델의 예측 성능을 평가하기 위해 MAE를 지표로 사용하였으며, 입력 구간의 변화에 따른 예측 안정성, 어텐션 기반 시각화 결과 등을 통해 모델의 일반화 가능성을 검증하였다. 실험결과 입력 구간이 전체 시퀀스의 10% 이하

일 경우에는 아래 그림 6과 같이 예측 오차의 범위가 급격히 증가하였으나, 25% 이상일 경우에는 아래 그림 7과 같이 오차가 감소하며 수렴하는 경향을 보였다. 표 3는 입력 구간의 길이가 학습 시퀀스의 10%, 15%, 20%, 25%, 30%일 때 Test dataset의 10회 predict 결과에 대한 평균 MAE이다.




그림 6 Input Sequence Ratio : 10%




그림 7 Input Sequence Ratio : 25%

표 3 입력 시퀀스 비율에 따른 평균 MAE

| NO.\ratio | 10%    | 15%    | 20%    | 25%    | 30%    |
|-----------|--------|--------|--------|--------|--------|
| 1         | 0.2610 | 0.1843 | 0.1511 | 0.0434 | 0.0389 |
| 2         | 0.3325 | 0.2698 | 0.1762 | 0.1173 | 0.0972 |
| 3         | 0.2911 | 0.2582 | 0.1913 | 0.1008 | 0.0829 |
| 4         | 0.1834 | 0.1429 | 0.0989 | 0.0728 | 0.0675 |

또한, 아래 표 4와 같이 기존 베이스라인 모델인 ARIMA 모델과 GRU 셀을 이용하여 10%와 25% 시퀀스 길이로 동일 테스트를 시행하였다. 10% 이하의 입력 시퀀스에 대해서는 본 연구의 모델이 GRU 셀보다 낮은 성능을 가지지만, 입력 시퀀스 길이가 25% 일때와 같이 입력 시퀀스가 길수록 더 좋은 성능을 보임을 확인할 수 있었다.

표 4 입력 시퀀스 비율별 모델 성능(MAE) 비교

| Model\ratio | 10%    | 25%    |
|-------------|--------|--------|
| E-D LSTM    | 0.2610 | 0.0434 |
| ARIMA       | 0.329  | 0.142  |
| GRU         | 0.217  | 0.098  |

## 4.2 attention heatmap 분석

그림 8은 어텐션 모듈을 통해 산출된 어텐션 가중치를 시각화한 결과로, 모델이 출력 시점마다 입력 시퀀스의 어느 부분에 집중했는지를 보여준다. 세로축은 입력 시점(Input Steps), 가로축은 출력 시점(Output Steps)을 나타내며, 색상은 해당 시점의 어텐션 가중치 크기를 의미한다.

Heatmap을 보면, 상단에 가까운 영역일수록 높은 가중치를 갖고 있어 모델이 전체 출력 과정에서 상대적으로 최근 입력 정보에 더 큰 가중치를 부여했음을 알 수 있다.




그림 8 Attention Heatmap

장기 예측 구간으로 갈수록 어텐션이 특정 입력 시점에 집중되기보다는 전체적으로 분산되는 경향을 보이나, 여전히 최근 입력값의 영향력이 유지되어 장기 예측에서도 일정 수준의 기여를 하고 있음을 확인할 수 있다.

## 4.3 결론

본 연구에서는 바나나의 시계열 이미지 데이터를 기반으로, 초기 일부 시간 구간의 신선도 정보를 입력받아 전체 시간 구간에 대한 신선도 변화를 예측할 수 있는 모델을 제안하였다. 인코더-디코더 구조에 기반한 본 모델은 가변 길이 입력을 효과적으로 처리할 수 있도록 설계되었으며 Repeat-Vector-Dynamic 레이어와 Attention 메커니즘을 통합함으로써 다양한 입력 길이에 대해 유연하고 정확한 예측이 가능함을 확인하였다. 특히 모델의 입력 시퀀스가 전체의 25% 이상을 포함할 경우, 기존 베이스라인 모델들보다 최대 3~5배이상 좋은 성능을 나타내는 것을 확인할 수 있었으며, 모델이 예측한 신선도의 변화의 MAE 값이 수렴하는 것을 확인할 수 있었다.

본 연구는 제한된 환경에서의 기존의 이미지 기반 단순 신선도 등급 분류 방식이나 단기적인 변화만을 예측하는 모델들과 달리, 다양한 환경에서 신선도의 연속적이고 장기적인 변화를 예측한다는 점에서 차별성이 있다. 또한, 본 모델은 실시간 신선도 모니터링 및 저장 시스템과 연계하여 사용할 경우 실질적인 스마트팜 시스템에서 사용할 수 있을것으로 기대된다.

## 5. 참고 문헌

- [1] 김영민, 박승민. “딥러닝기반 YOLO를 활용한 후숙과일 분류 및 숙성 예측 시스템”. 2021년 한국컴퓨터정보학회 하계학술대회. (2021).
- [2] Benoit Daviet, et al. "Ripening dynamics revisited: an automated method to track the development of asynchronous berries on time-lapse images". Plant Methods. (2023).
- [3] Enoc Tapia-Mendez, et al. "Deep Learning-Based Method for Classification and Ripeness Assessment of Fruits and Vegetables". Appl.Sci. (2023).
- [4] Vikas Kjullar, et al. "Intelligent fruit quality classification system using transfer learning". Autonomous Intelligence. (2024).
- [5] Ilya Sutskever, et al. "Sequence to Sequence Learning with Neural Networks". NIPS. (2014).
- [6] Dzmitry Mahdanau, et al. "Neural Machine Translation by Jointly Learning to Align and Translate". ICLR. (2015).
- [7] Thomas Rojat, et al. "Explainable Artificial Intelligence (XAI) on Time Series Data: A Survey". arXiv:2104.00950 (2021).
- [8] S. A. Siddiqui, et al. "TSViz: Demystification of deep learning models for time-series analysis" IEEE. (2019).
- [9] Hao Guo, et al. "Visual Attention Consistency under Image Transforms for Multi-Label Image Classification". IEEE. (2019).